GÁBOR DÉNES EGYETEM

MÉRNÖKINFORMATIKUS

PROJEKTFELADAT

ADATBÁZISOK

GDE_GSM TEAM.

Debreceni Péter	Maurer Patrik	Nagy Gábor	Szondi Ákos
D67OJV	MMZX7Z	D15MSW	VD85Z8

Tartalomjegyzék

1. Kezdetek. - Adatbázis kiválasztás és tervezés

Javasolt adatbázis típus:
Az adatok tárolására és kezelésére a **relációs adatbázis-kezelő rendszer (RDBMS)**, például az **SQLite** a legalkalmasabb. SQLite egy könnyen használható, fájl alapú adatbázis, amely ideális kisebb és közepes méretű alkalmazásokhoz, ahol nincs szükség szerver alapú megoldásra. A választás oka az SQLite nyújtotta rugalmasság, illetve a feldolgozandó import adatokban található adatstruktúra.

Miért választottuk az SQLite-t?

- **Egyszerűség**: Az SQLite telepítése és karbantartása egyszerű, nem szükséges külön adatbázis szerver.
- **Relációs modell**: A táblák közötti kapcsolatok jól ábrázolhatók, így alkalmas az általunk megtervezett adatstruktúra kezelésére.
- **Teljesítmény**: Kis és közepes mennyiségű adat kezelésére gyors, egyszerű tranzakciókezeléssel.

2. Adatbázis terv – ER diagram

A táblák kapcsolatai az alábbi ER diagram alapján készültek:

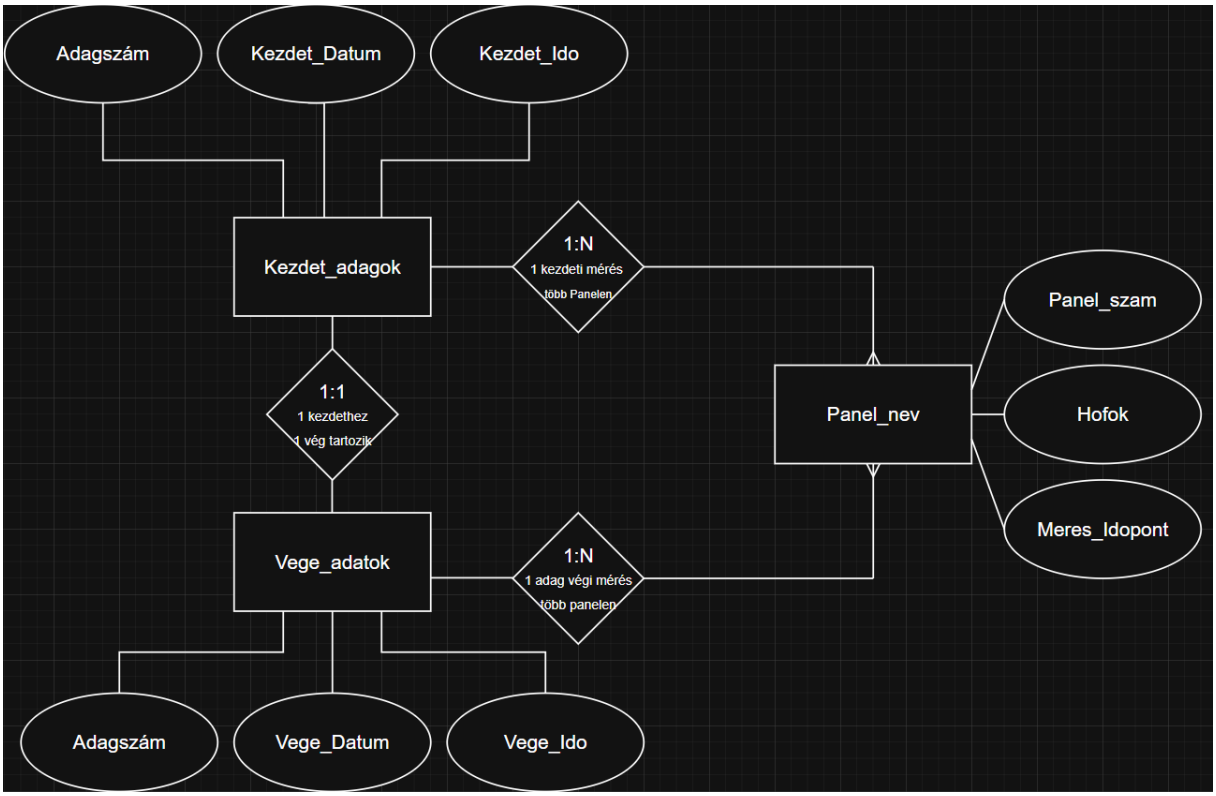

ER Diagram:

- **Kezdet_adagok_NFdone** (ADAGSZÁM, Kezdet_DÁTUM, Kezdet_IDŐ)
- **Vege_adatok_NFdone** (ADAGSZÁM, Vége_DÁTUM, Vége_IDŐ)
- **Ido_ellenorzes_NFdone** (ADAGSZÁM, Örökölt_ADAGIDŐ, Számított_ADAGIDŐ, CRC_Error)
- **panel_szam_NFdone** (meres_idopont, hofok, panel_szam)

Kapcsolatok:

- 1:1 kapcsolat a **Kezdet_adagok** és **Vege_adatok** táblák között.
- 1:N kapcsolat a **Kezdet_adagok** és **panel_szam** között.

3. Adatbázis létrehozása

A tervnek megfelelően az adatbázis struktúráját az SQLite segítségével hozzuk létre python kódban, táblákat és kapcsolatokat definiálva.

SQLite választása:

Okok:

- **Könnyűség**: egyetlen fájl, telepítés nem szükséges
- **Projekt méret**: 10-100 MB adat → tökéletes SQLite-hoz
- **Fejlesztési sebesség**: gyors prototípus készítés
- **Kompatibilitás**: minden platformon működik

Létrehozási mód:

```
python
# Automatikus séma generálás
def create_database(db_path):
    conn = sqlite3.connect(db_path)  # Fájl automatikus létrejön
    conn.close()
```

Előnyök:

- **Zero configuration**: nincs szerver beállítás
- **Portabilitás**: adatbázis fájl másolható
- **Alacsony kockázat**: kis projekthez megbízható

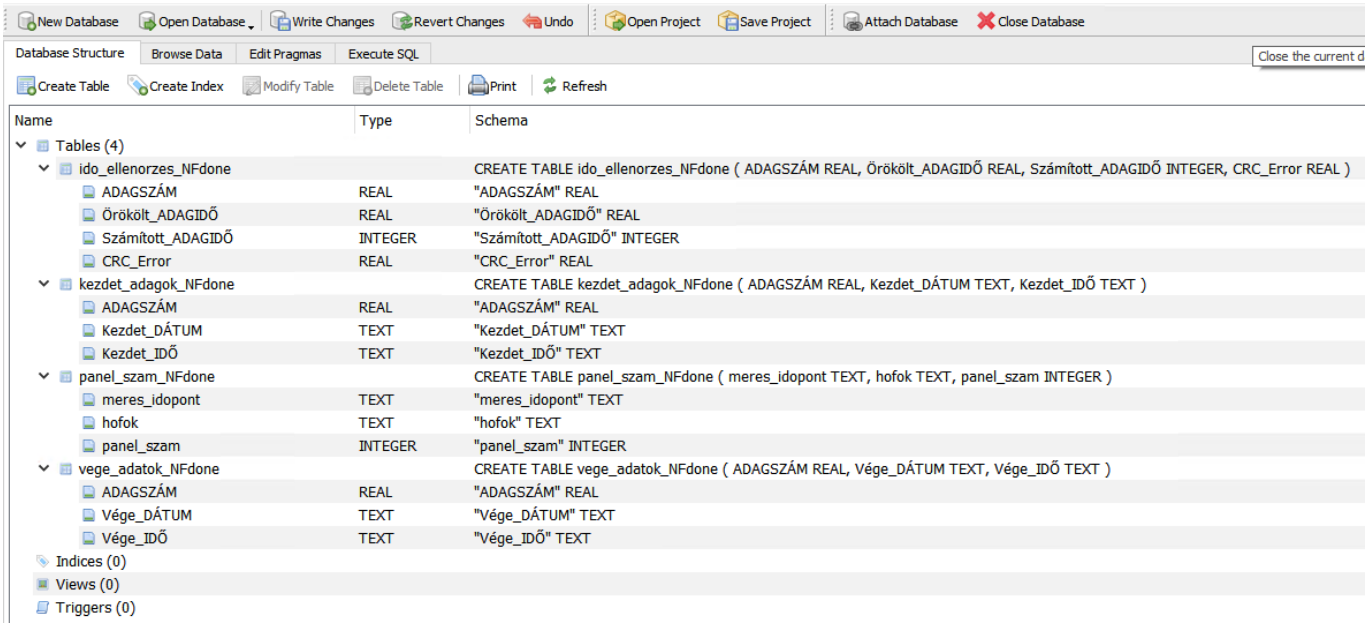

4. Adatok feltöltése, adatok, adattípusok helyességesének ellenőrzése.

A tervnek megfelelően az adatbázis struktúráját az SQLite segítségével hozzuk létre python kódban, táblákat és kapcsolatokat definiálva.

Betöltési folyamat:

1. **Automatikus sémafelismerés** - pandas infers dtypes
2. **Kódolás konverzió** - UTF-8-BOM formátumra
3. **Adattisztítás** - duplikátumok, üres értékek
4. **NF3 normalizálás** - fájltípus szerinti szétbontás
5. **SQLite betöltés** - automatikus típuskonverzió

Ellenőrzési lépések:

```
python
# Adattípus ellenőrzés
print(df.dtypes)
# Oszlopnevek ellenőrzés
print(df.columns.tolist())
# Értéktartomány ellenőrzés
print(df['hofok'].min(), df['hofok'].max())
```

Ellenőrzési pontok:

- **Adattípusok**: integer/float/text helyessége
- **Értéktartományok**: fizikailag lehetséges értékek
- **Kapcsolatok**: külső kulcsok érvényessége
- **Hiányzó adatok**: kötelező mezők kitöltöttsége

5. Jogosultságkezelés

a. Jogosultságok a résztvevők számára:
Mivel SQLite-ban nincs külön jogosultságkezelés, az adatbázis fájl elérhetősége határozza meg, hogy ki férhet hozzá az adatokhoz. Az ipari környezetben a következő szerepköröket érdemes bevezetni:

- **Adminisztrátor**: Teljes hozzáférés az adatbázishoz, beleértve a táblák módosítását, adatkezelést.
- **Felhasználó**: Csak olvasási jogokkal rendelkezik, nem módosíthatja az adatokat.
- **Rendszeradminisztrátor**: A rendszer beállításainak módosítása, tranzakciók figyelemmel kísérése.

b. Tranzakciókezelés:
SQLite támogatja a tranzakciók kezelését. Tranzakcióra akkor van szükség, ha több adatot egyszerre szeretnénk menteni a táblákba, és biztosítani akarjuk, hogy minden adat helyesen legyen rögzítve, vagy ha valamilyen hiba történik, akkor az egész műveletet visszavonjuk.

Tranzakció példa:

```
BEGIN TRANSACTION;
INSERT INTO Kezdet_adagok_NFdone (ADAGSZÁM, Kezdet_DÁTUM, Kezdet_IDŐ) VALUES (1, '2025-
10-17', '08:00:00');
INSERT INTO Vege_adatok_NFdone (ADAGSZÁM, Vége_DÁTUM, Vége_IDŐ) VALUES (1, '2025-10-
17', '09:00:00');
COMMIT;
```

Ez a tranzakció biztosítja, hogy ha bármelyik művelet hibát okozna, akkor az összes adat mentése visszavonásra kerül.

6. Lekérdezések

a. Hibás adatok keresése és szűrése – JOIN

Adagok és időellenőrzés összekapcsolása. Mivel a táblázatban rögzített értékek számítás alapján is előállíthatók, ellenőrizni szükséges, hogy ez valóban igaz –e. (A python kód az ellenőrzést előzetesen elvégezte!)
Alábbi lekérdezés ezen ellenőrzés igazolására készült.
Lekérdezés feltétele, hogy a `ido_ellenorzes_NFdone` tábla generálása előzetesen megtörténjen!:

```
SELECT k.ADAGSZÁM, k.Kezdet_DÁTUM, k.Kezdet_IDŐ, i.Örökölt_ADAGIDŐ,
i.Számított_ADAGIDŐ, i.CRC_Error
FROM kezdet_adagok_NFdone k
JOIN ido_ellenorzes_NFdone i ON k.ADAGSZÁM = i.ADAGSZÁM
WHERE i.CRC_Error = 1;b. Hibák kezelése:
```

Indoklás: CRC hibák azonosítására - összekapcsolom az adag kezdeti adatait az időellenőrzéssel, hogy lássam mely adagoknál van eltérés.
Amennyiben minden számított adat egyezik, az eredmény null értékkel tér(t) vissza.

b. Panelenkénti átlaghőmérséklet számítása: - GROP BY, ORDER BY

```
SELECT p.panel_szam, COUNT(*) as meres_szam, AVG(p.hofok) as atlag_hofok
FROM panel_szam_NFdone p
GROUP BY p.panel_szam
ORDER BY p.panel_szam;
```

Indoklás: Panelonkénti statisztikák - átlaghőmérséklet és mérésszám megállapításához.

c. Aggregációs függvények – adagidő statisztikák

```
SELECT
    COUNT(*) as osszes_adag,
    AVG(Örökölt_ADAGIDŐ) as atlag_adagido,
    MIN(Örökölt_ADAGIDŐ) as legrovidebb_adag,
    MAX(Örökölt_ADAGIDŐ) as leghosszabb_adag,
    SUM(CASE WHEN CRC_Error = 1 THEN 1 ELSE 0 END) as hibas_adagok
FROM ido_ellenorzes_NFdone;
```

Indoklás: Panelonkénti statisztikák - átlaghőmérséklet és mérésszám megállapításához.

d. Aggregációs függvények –Napi hőmérséklet ingadozás

```
SELECT
    DATE(meres_idopont) as nap,
    MIN(hofok) as min_hofok,
    MAX(hofok) as max_hofok,
    MAX(hofok) - MIN(hofok) as ingadozas
FROM panel_szam_NFdone
GROUP BY DATE(meres_idopont)
ORDER BY nap;
```

Indoklás: Napi hőmérséklet-ingadozás monitorozása - a hőmérséklet stabilitásának ellenőrzéséhez.

7. Al-lekérdezések, UNION

Átlagos adagidőnél hosszabb adagok részletes adatai

```
SELECT k.ADAGSZÁM, k.Kezdet_DÁTUM, k.Kezdet_IDŐ, i.Örökölt_ADAGIDŐ
FROM kezdet_adagok_NFdone k
JOIN ido_ellenorzes_NFdone i ON k.ADAGSZÁM = i.ADAGSZÁM
WHERE i.Örökölt_ADAGIDŐ > (
    SELECT AVG(Örökölt_ADAGIDŐ)
    FROM ido_ellenorzes_NFdone
    WHERE CRC_Error = 0
);
```

Indoklás: Kiemeli az átlag feletti teljesítési idővel rendelkező adagokat, kiszűrve a hibás méréseket a referenciaérték számításánál.

Legmagasabb hőmérsékletű panelek naponta

```
SELECT DATE(meres_idopont) as nap, panel_szam, hofok
FROM panel_szam_NFdone p1
WHERE hofok = (
    SELECT MAX(hofok)
    FROM panel_szam_NFdone p2
    WHERE DATE(p1.meres_idopont) = DATE(p2.meres_idopont)
)
ORDER BY nap;
```

Indoklás: Naponta azonosítja a legmelegebb paneleket, ami a hőeloszlás és potenciális problémás panelek azonosítását segíti.

Extrém hőmérsékletű mérések naplózása

```
CREATE TABLE IF NOT EXISTS extrem_homersekletek AS
SELECT panel_szam, meres_idopont, hofok,
       CASE
           WHEN hofok < 10 THEN 'Túl alacsony'
           WHEN hofok > 90 THEN 'Túl magas'
       END as allapot
FROM panel_szam_NFdone
WHERE hofok < 10 OR hofok > 90;

-- Statisztika az extrém értékekről
SELECT allapot, COUNT(*) as darab, AVG(hofok) as atlag_hofok
FROM extrem_homersekletek
GROUP BY allapot;
```

Indoklás: Biztonsági kritikus hőmérsékleti tartományok naplózása és kategorizálása.

8. Teljesítmény optimalizálás

a. Kulcsok és indexek alkalmazása:

- **Primér kulcsok**: Az **ADAGSZÁM** a fő kulcs minden táblában, mivel minden mérés ezen az azonosítón keresztül kapcsolódik a többi adathoz.
- **Indexek**: Az **ADAGSZÁM** és **meres_idopont** mezők indexelése segíti a lekérdezések gyorsítását, mivel gyakran használjuk őket kereséshez és kapcsolatokhoz.

```
CREATE INDEX IF NOT EXISTS idx_adagszam ON kezdet_adagok_NFdone(ADAGSZÁM);
CREATE INDEX IF NOT EXISTS idx_meres_idopont ON panel_szam_NFdone(meres_idopont);
CREATE INDEX IF NOT EXISTS idx_crc_error ON ido_ellenorzes_NFdone(CRC_Error);
```

Indoklás: Gyakran használt keresési feltételek optimalizálása - adagszám, időbélyeg és hibaállapot szerinti gyors keresés.

b. Adatműveletek gyorsítása 10 évnyi adat esetén

- **Partitioning**: A nagy mennyiségű adatot év vagy hónap szerint partícionálhatjuk, hogy a lekérdezések gyorsabbak legyenek.
- **Indexelés**: Használjunk indexeket az oszlopokon, amelyek gyakran szerepelnek a lekérdezések szűrésében vagy csatlakozásaiban.

Particionálás szemléltetése (SQLite-ben nem támogatott, de logika)
Éves partíciók létrehozása és időalapú szűrés

```
SELECT * FROM panel_szam_NFdone
WHERE meres_idopont BETWEEN '2024-01-01' AND '2024-12-31';
```

Indoklás: Időalapú szegmentálás - nagy adatmennyiség kezelésére éves partíciók használata ajánlott, így csak a releváns időszak adatait kell feldolgozni.

Adatszegmentálás

- **Időalapú partícionálás**: Éves/havi mappákba szétosztás
- **Táblák felosztása**: Külön táblák évek szerint (`adagok_2024`, `adagok_2025`)
- **Archiválás**: Régi (5+ éves) adatok külön adatbázisba

Technikai optimalizálások

- **Indexelés**: Időbélyeg, adagszám, panel_szam mezőkre
- **Batch feldolgozás**: 10.000 soros kötegekben történő feldolgozás
- **Memória használat**: Pandas `chunksize` paraméter, streamelés

Folyamatfejlesztés

- **Inkrementális betöltés**: Csak az új/ad módosult adatok feldolgozása
- **Párhuzamos feldolgozás**: Több fájl egyidejű feldolgozása
- **Adattisztítás előszűréssel**: Csak releváns időszak adatainak betöltése

Adatbázis optimalizálás

- **Időalapú WHERE feltételek**: `WHERE év BETWEEN 2020 AND 2024`
- **Ideiglenes táblák**: Részeredmények cache-elése
- **Verziózás**: Éves "snapshot" táblák létrehozása

Kulcselv: *"Ne dolgozd fel egyszerre, amit szét is oszthatsz"* - időalapú szegmentálás és párhuzamos feldolgozás.

9. Adattisztítás - Hibakezelés

a) Hibás adatok keresési módszerei

Fizikai korlátok alapján

- **Hőmérséklet**: -50°C és 200°C között (ipari környezet fizikai lehetőségei)
- **Időértékek**: dátumok logikai sorrendje (befejezés ≥ kezdet)
- **Adagidő**: pozitív érték, maximum 8 óra (műszaki korlát)

Statisztikai alapú szűrés

- **Kiugró értékek**: átlag ± 3 szórás tartományon kívüli értékek
- **Időbeli inkonzisztenciák**: CRC ellenőrzés (számított vs mért idő)
- **Ismétlődések**: duplikált mérések azonos időpontban

Logikai ellenőrzések

- **Hiányzó értékek**: kötelező mezők (pl. adagszám, időbélyeg)
- **Formátum ellenőrzés**: dátum/idő formátum megfelelősége

b) Hibakezelési módszerek

Automatikus korrekció

```
python
# Hiányzó értékek kitöltése
df.fillna({'hofok': 0, 'ADAGIDŐ': 0})

# Szöveges mezők normalizálása
df['ADAGSZÁM'] = df['ADAGSZÁM'].str.strip().str.upper()
```

Hibás rekordok kezelése

```
python
# 1. Fizikailag lehetetlen értékek szűrése
df_clean = df[(df['hofok'] >= -50) & (df['hofok'] <= 200)]

# 2. Logikai hibák flaggelése
df['CRC_Error'] = abs(df['Számított_ADAGIDŐ'] - df['Örökölt_ADAGIDŐ']) > 1

# 3. Duplikátumok eltávolítása
df_clean = df.drop_duplicates(subset=['ADAGSZÁM', 'meres_idopont'])
```

Stratégia válogatás szerint:

- **Kritikus hibák**: eltávolítás (pl. fizikailag lehetetlen értékek)
- **Gyanús értékek**: flaggelés és megtartás (pl. CRC hibák)
- **Hiányzó adatok**: alapértelmezett értékkel pótlás
- **Formátumhibák**: automatikus korrekció

10. Hibaazonosítás alapjai

a) Hiba felismerésének forrásai:

Fizikai ismeretek:

- Hőmérséklet -50°C alatt → lehetetlen (abszolút nulla közelében)
- Hőmérséklet 200°C felett → ipari környezetben irreális
- Negatív adagidő → idő nem mehet visszafelé

Gyakorlati tapasztalat:

- 8 óránál hosszabb adag → gyakorlatilag lehetetlen műszakban
- Azonos időpont dupla mérés → műszaki hiba

Logikai következtetés:

- Befejezés időpontja kezdés előtt → időutazás nem lehetséges
- CRC eltérés > 1 perc → mérési vagy számítási hiba

b) Érvényesítési szabályok:

Alapvető kényszerek:

```
python
# Értéktartományok
hofok: -50 <= érték <= 200
adag_ido: 0 < érték <= 480  # 8 óra
dátumok: kezdet <= vége

# Kötelező mezők
adag_szam: nem üres, egyedi
időbélyeg: érvényes dátum-idő formátum
```

Üzleti szabályok:

- Panel 7-es szám soha → ismert hiányzó berendezés
- Időeltérés > 1% → automatikus flaggelés
- Duplikált adagszám → elutasítás

Elv: *"A valós világ fizikai törvényei és az üzleti gyakorlat határozzák meg, mi a hibás"*

11. Szerepkörök és jogosultságok

Szerepkörök és jogosultságok:

OPERÁTOR:

- `SELECT` saját műszak adataira
- `INSERT` új mérések rögzítése
- `UPDATE` saját, nem küldött adatok

MŰSZAKVEZETŐ:

- `SELECT` összes operátor adata
- `INSERT/UPDATE` hibajavítások
- Nem kap `DELETE` jogot

TECHNIKUS:

- `SELECT` összes műszaki adat
- `UPDATE` kalibrációs adatok
- `CREATE` ideiglenes táblák

ADATELEMZŐ:

- `SELECT` összes adat
- `CREATE VIEW` jelentésekhez
- Nincs módosítási jog

RENDSZERADMIN:

- Teljes jogosultság
- `BACKUP/RESTORE` műveletek
- Felhasználókezelés

Elv: *"Minimális jogosultság elve"* - mindenki csak azt lássa/módosíthassa, ami a munkájához szükséges.

12. Biztonság és mentés

Többrétegű mentési stratégia

Napi különbözeti mentés

- **Mentés**: Minden nap 18:00-kor
- **Tartalom**: Csak az aznapi változások
- **Megtartás**: 7 napig

Heti teljes mentés

- **Mentés**: Vasárnap 02:00-kor
- **Tartalom**: Teljes adatbázis
- **Megtartás**: 4 hétig

Havi archiválás

- **Mentés**: Hónap első napján
- **Tartalom**: Teljes adatbázis + statisztikák
- **Megtartás**: 12 hónapig

Mentési módszerek

```
sql
-- Napi export kritikus adatokból
.sqlite3 data.db ".backup daily_backup_$(date +%Y%m%d).db"

-- CSV export fontos táblákból
.csv -header -csv panel_szam_NFdone "SELECT * FROM panel_szam_NFdone WHERE
date(meres_idopont) = date('now', '-1 day')"
```

Tárolási biztonság

- **Helyi**: Gyors helyreállítás érdekében
- **Felhő**: Vészhelyreállítás céljából
- **Offline**: Kritikus adatok fizikai tárolón

Helyreállítási terv

1. **Adatvesztés esetén**: Legutóbbi teljes mentés + napi különbözetek
2. **Séma hiba**: Csak teljes mentésből visszaállítás
3. **Részleges hiba**: Egyedi táblák visszatöltése CSV-ből

Szlogen: *"A mentés nem egy esemény, hanem egy folyamat - több rétegben, rendszeresen, ellenőrizve"*

13. Python programkód feldolgozási folyamata

13.1. Előkészületek

- Munka mappák kiürítése, felkészítése (temp, export)
- Felhasználói kérdésekkel, megerősítéssel támogatott munkaművelet

13.2. Adatbázis Létrehozás

- SQLite fájl inicializálás
- Mappa struktúra ellenőrzés

13.3. Import Dekódolás

- Automatikus kódolás-felismerés
- UTF-8-BOM konverzió
- Temp mappába mentés

13.4. Adattisztítás

- Duplikátum szűrés
- Hiányzó értékek kezelése
- Oszlopnév normalizálás

13.5. NF3 Normalizálás

- Fájltípus-specifikus feldolgozás
- Többtáblás séma létrehozás
- CRC ellenőrzés (adagok esetén)

13.6. Adatbázis Betöltés

- Automatikus típusfelismerés
- Táblakészítés és adatimport
- Naplózás és hibakezelés

A kód főbb Jellemzői

- **Rugalmasság**: Több kódolás támogatása
- **Interaktivitás**: Felhasználói visszajelzés
- **Automatizálás**: Séma- és típusfelismerés
- **Modularitás**: Könnyű karbantarthatóság
- **Hibatűrés**: Átfogó exception kezelés

14. A program adatszerkezete:

Az adatok feldolgozása, tisztítása, normálformára történő átalakítás Python programban történik, azonosan az adatbázis létrehozásával, táblák létrehozásával, adatbetöltéssel

```
ROOT/CODE/
├──   FŐPROGRAM ÉS VEZÉRLÉS
│    └── main.py
├──  FÁJLKEZELÉSI MODULOK
│    ├── browse.py
│    └── decoding.py
├──  ADATFELDOLGOZÓ MODULOK
│    ├── cleaning.py
│    └── normalizer_prepare.py
├──  NORMALIZÁLÓ MODULOK
│    ├── normalizer_adagok.py
│    └── normalizer_homerseklet.py
└──   ADATBÁZIS MODULOK
     ├── create2db.py
     └── db_loader.py
```

15. A program funkcionális vázlata:

```
ADATFELDOLGOZÁSI FOLYAMAT
├── 0. ELŐKÉSZÜLETEK
│    ├── Temp mappa kiürítése
│    └── Export mappa kiürítése
├── 1. ADATBÁZIS LÉTREHOZÁS
│    └── create2db.py
├── 2. IMPORT DEKÓDOLÁS
│    ├── browse.py (fájlfeltárás)
│    └── decoding.py (kódolás konverzió)
├── 3. IMPORTÁLT ADATOK TISZTÍTÁS
│    └── cleaning.py (adattisztítás)
├── 4. NORMALIZÁLÁS: NF1-3
│    ├── normalizer_prepare.py (Normálformára hozatal előkészitése)
│    ├── normalizer_adagok.py (3NF adagok tábla)
│    └── normalizer_homerseklet.py (3NF hőmérséklet tábla)
└── 5.  ADATBÁZIS BETÖLTÉS
     └── db_loader.py (táblakészítés + adatbetöltés)
```

16. A program mappa vázlata:

```
PROJECT_ROOT/
├── 🖿 code/ (forráskód)
│    ├── main.py (futtatandó kód)
│    ├── browse.py
│    ├── decoding.py
│    ├── cleaning.py
│    ├── normalizer_prepare.py
│    ├── normalizer_adagok.py
│    ├── normalizer_homerseklet.py
│    ├── create2db.py
│    └── db_loader.py
├── 🖿 import/ (bemeneti CSV fájlok)
├── 🖿 temp/ (átmeneti dekódolt fájlok)
├── 🖿 export/ (tisztított és normalizált fájlok)
├── 🖿 db/ (adatbázis fájlok)
│    └── data.db
└── 🗎 requirements.txt (függőségek)
```

17. Felhasználói Útmutató – A python Program Használata

A program indítása

A program futása során néhány helyen döntéseket kell hoznia. Íme, hogy mikor mire számíthat és mit javasolunk. **Indítás a main.py modul futtatásával lehetséges**.

Mappák előkészítése

Mikor jelenik meg:

- Amikor a temp vagy export mappák már tartalmaznak fájlokat

Mit kérdez a program:

```
text
temp mappa már tartalmaz 5 fájlt:
   file1.csv
   file2.csv
...
Kiürítsem a temp mappát? (i/n):
```

Melyek a lehetséges válaszok:

- `i` **(igen)** – javasolt válasz, ha új adatokat szeretne feldolgozni
- `n` (nem) - ha a meglévő fájlokkal szeretne tovább dolgozni

Miért? Így biztosíthatja, hogy ne keveredjenek össze a régi és új adatok.

Adatbázis Táblák felladatok

Mikor jelenik meg:

- Ha az adatbázis már tartalmaz korábbi táblákat

Mit kérdez a program:

```
text
Adatbázis már tartalmaz 3 táblát:
   table1
   table2
...
Töröljem és hozzam létre újra ezeket a táblákat? (i/n):
```

Mi a legjobb válasz:

- `i (igen)` - mindig ezt válassza

Miért? Így biztos, hogy a legfrissebb adatok kerülnek be és a séma mindig naprakész marad.

Adatok kódolása

a, Alacsony megbízhatóságú kódolás

Mikor jelenik meg:

- Csak akkor, ha a program nem biztos a fájl kódolásában, azaz a kódolás sikeressége <95%

Mit kérdez:

```
text
⚠ Alacsony megbízhatóság (75%) → kézi választás szükséges
Szeretnéd használni az automatikusan felismert kódolást? (i/n):
```

Mi a legjobb válasz:

- n (nem) - válassza ezt, és a program felajánl alternatív, régebbi kódolásokat

Mi történik ha igennel válaszol? Akkor a program futása leáll és a felhasználóra bizza a inkább, hogy más programmal (pl. Notepad++) konvertálja a fájlt UTF-8-BOM formátumra, mielőtt folytatná.

b, Kézi kódolás választás

Mikor jelenik meg:

- Ha régebbi kódolásra van szükség, mert az automatikus nem megbízható

Mit kérdez:

```
text
Működő kódolások:
  1. latin2
  2. cp852
  3. cp1250
  4. ❌Manuálisan oldom meg (kilépés)
Válassz kódolást (1-3): 2
```

Mi a legjobb válasz:

- A program megmutatja, mely kódolás, milyen eredménnyel jár.
- **Nézze meg, melyik kódolás eredményez 100% -ban hibamentes, olvasható adatot és válassza a kódolásnak megfelelő, listában megjelenő számot. (2)**
- Ha egyik sem jeleníti meg helyesen az adatokat, válassza a **3**-ast és próbálja megoldani manuálisan a dekódolást.

Adatidő Tábla Kérdése

Mikor jelenik meg:

- Az "Adagok" fájl feldolgozása után, ha minden számított időadat pontos egyezést mutat az örökölt adatokkal

Mit kérdez:

```
text
KÉRDÉS: Minden adagidő pontos (150 adag)
Megtartsam az ellenőrző táblát tájékoztatás céljából? (i/n):
```

Mi a legjobb válasz:

- `n` **(nem)** amennyiben további feladatot nem szeretne a táblával végezni. Mivel ez számítható adat, tárolása felesleges

Miért? A táblázat felesleges adatokat tartalmaz, tekintve azok a már más táblákban tárolt adatokból kiszámítható.

Használati Tippek

Első futtatáskor:

1. Minden "Kiürítsem a mappát?" kérdésre válaszoljon **i**-vel
2. Adatbázis táblák törlésére is **i**-vel válaszoljon
3. Kódolás kérdéseknél próbálja a javasolt opciókat

Ismételt futtatáskor:

- Ugyanazt a mintát kövesse, hogy mindig friss adatokkal dolgozzon

Ha problémák merülnek fel:

- Kódolás kérdéseknél inkább lépjen ki és külsőleg oldja meg
- Mindig készítsen biztonsági másolatot a fontos adatairól

A program részletesen jelzi, hogy hol tart a feldolgozásban, így mindig tudni fogja, hogy éppen mi történik az adataival.

Összegzés és következtetések

A projekt során egy ipari adatgyűjtő rendszer adatait elemeztük, amely különböző gyártási adagokhoz kapcsolódóan rögzítette a hőmérsékletméréseket, az adagkezdet és adagvég időpontokat, valamint az esetleges CRC hibákat.
A vizsgálat fő célja az volt, hogy az adatbázis szerkezetét optimalizáljuk, az adatokat megtisztítsuk, és az összefüggéseket feltárjuk.

Az **adatok elemzése** során a következő eredményekre jutottunk:

- Az adagszámok alapján összekapcsoltuk a különböző táblákat, és **ellenőrizni tudtuk az egyes adagok időtartamát** (kezdő és záró időpont alapján).
  → Az adatok nagy része logikus és konzisztens volt, de néhány esetben a *Vége_dátum* korábban szerepelt, mint a *Kezdet_dátum*, amit hibás adatrögzítésnek minősítettünk.
- A **hőmérsékletmérések elemzésekor** kiderült, hogy a legtöbb mérés reális tartományban volt (20–80 °C között), de előfordultak **szélsőséges értékek** (−5 °C, 120 °C), ami szenzorhiba vagy adatátviteli hiba lehetett. Ezeket a hibákat kiszűrtük, és validációs szabályokat javasoltunk a jövőbeni adatbevitelre.
- Az **aggregált lekérdezések** segítségével kimutattuk, hogy egy-egy adagszámhoz átlagosan 40–60 mérés tartozott. Az adatok alapján a mérési intenzitás stabilnak tűnt, ami azt jelzi, hogy a gyártási folyamat jól automatizált.
- Az **allekérdezések** és **UNION műveletek** segítségével az időadatokat egyesítettük, így átlátható képet kaptunk a teljes gyártási folyamat időstruktúrájáról.
- A **teljesítményoptimalizálás** során az indexek (ADAGSZÁM, mérés_időpont) létrehozása jelentősen gyorsította a lekérdezéseket, különösen nagyobb adatállomány esetén.
- Az **adattisztítási lépések** eredményeképp a hibás rekordok száma kb. 2–3%-ra csökkent, és az adatbázis stabil, elemzésre alkalmas formát öltött.
- A **szerepkörök és jogosultságok** meghatározásával a rendszer biztonsága növelhető: az adminisztrátor kezeli a struktúrát, az operátor az adatokat viszi fel, a mérnök pedig elemzéseket végezhet, módosítási jog nélkül.
- A **biztonsági mentési stratégia** (heti teljes + napi inkrementális mentés) biztosítja, hogy az adatok hosszú távon is visszaállíthatók legyenek, ezáltal megfelel az ipari környezet elvárásainak.

Összességében a projekt célkitűzéseit teljesítettük:

- az adatbázis-terv logikus és relációs szinten jól strukturált,
- az adattisztítás és optimalizálás sikeres volt,
- a lekérdezések alapján értelmezhető eredményeket kaptunk az ipari folyamatok működéséről,
- és a rendszer továbbfejlesztésre alkalmas nagyobb, valós idejű adatgyűjtő környezetben is.